

Rapport final du cours IFT 3150

Projet Axel
Agent conversationnel basé sur LLaMA 3

Realisé par
Qiwu Wen
Matricule: 20230961
Courriel: qiwu.wen@umontreal.ca

Organisation: Laboratoire RALI, DIRO, Université de Montréal
Supervisé par : Prof. Jian-Yun Nie
courriel: nie@iro.umontreal.ca

Table des matières

[1.Introduction](#)

[1.1 Description du projet](#)

[1.2 Application des techniques d'apprentissage profond](#)

[1.3 La version de l'agent conversationnel basée sur Llama 3](#)

[1.4 Résumé des travaux à présenter dans ce rapport](#)

[2. L'étude de compréhension émotionnelle des grands modèles](#)

[2.1 Intelligence émotionnelle chez les humains](#)

[2.2 Intelligence émotionnelle chez les modèles](#)

[2.3 Évaluation les capacité de différents modèles](#)

[2.4 Analyse des résultats](#)

[3. Classificateur d'émotions](#)

[3.1 Classificateur basé sur le modèle pré-entraîné: BERT](#)

[3.1.1 Structure de prétraitement des données](#)

[3.1.2 Mesures d'évaluation](#)

[3.1.3 Réglage des hyperparamètres](#)

[3.1.4 Comparaison entre le modèle RoBERTa et le modèle BERT](#)

[4. Contrôle d'émotion](#)

[4.1 La matrice de transition émotionnelle](#)

[4.2 L'utilisation de la matrice de transition en utilisant le classificateur BERT \(Devlin et al. 2019\)](#)

[4.2.1 Discussion sur des cas particuliers](#)

[4.2.2 Module de conversion d'émotion](#)

[4.2.3 Contrôle de la longueur de la fenêtre](#)

[5. Affinage \(fine-tuning\) du modèle Llama 3](#)

[5.1 Aperçu du LoRA](#)

[5.2 Utilisation de certains outils open source](#)

[5.2.1 Outil pour effectuer l'entraînement du modèle](#)

[5.2.2 Quantification et conversion du model](#)

[5.2.3 Inférence et de déploiement](#)

[5.3 Utilisation de l'ensemble de données Open Assistant](#)

[5.3.1 Ensemble de données Open Assistant](#)

[5.3.2 Entraînement et évaluation du modèle](#)

[5.3.3 Observations et changement de direction](#)

[5.4 Métrique d'évaluation humaine](#)

[5.4.1 Les métriques classique pour la génération de langage naturel \(NLG\)](#)

[5.4.2 Les métriques EPITOME](#)

[5.4.3 Évaluations supplémentaires](#)

[5.5 Utilisation de l'ensemble de données EPITOME](#)

[5.5.1 Prompt pour la tâche de conversation](#)

[5.5.2 Évaluation humaine](#)

[5.6 Génération des données de haute qualité à l'aide de modèles GPT](#)

6. Propositions pour améliorations futures

6.1 Évaluation humaine et optimisation du modèle d'affinage DPO (Rafailov et al., n.d.)

6.2 Informations et préférences du personnage fictif "Axel"

6.2.1 Une option possible : RAG

6.2.2 Génération des informations personnelles et des expériences en temps réel

6.3 Scénario spécial dans le cas d'interruption de la parole

6.4 Adaptation au français

7. Conclusion

8. References

Annexe 1: prompt utilisé pour le test SECEU

Annexe 2: Exemples de Few-Shot Prompt pour Générer des Réponses avec une Émotion de Colère

Annexe 3: Prompt Utilisé pour l'Évaluation Humaine des Modèles Llama EPI et Llama 3

1.Introduction

1.1 Description du projet

La crise épidémique de 2019, qui a eu un impact énorme sur le monde, a changé la vie de nombreuses personnes. En raison des besoins de santé, de nombreuses personnes ont été contraintes de se mettre en quarantaine pour éviter la propagation du virus. Ce changement a forcé plusieurs CHSLD du Québec à isoler des personnes âgées qui étaient déjà immunisées et qui avaient encore besoin de soins. Ceci les a déconnectés de la société et a entraîné des problèmes psychologiques, tels que la solitude. Afin d'atténuer la solitude des personnes âgées et de les faire se sentir accompagnées, l'utilisation de robots d'assistance sociale (SAR) (Ostrowski et al. 2019) pour éliminer la solitude et l'isolement social est une solution à cette situation causée par l'épidémie (Getson and Nejat 2021). Notre projet Axel vise à développer un robot d'assistance sociale capable de discuter avec les personnes âgées pour atténuer le problème d'isolement social de ce groupe ayant besoin de soins.

Le projet Axel utilise un robot d'assistance sociale *open source* appelé T-Top (Maheux et al. 2022), conçu pour une interaction continue avec les humains. Il contient des capteurs audio et visuels avancés, des fonctions de traitement de la perception et de télécommunication par apprentissage profond, et dispose de méthodes d'interaction riches. L'image du robot T-top est à la figure 1.

Axel, le nom de notre robot, est conçu pour agir comme un assistant. Il interagit avec les résidents de CHSLD par la reconnaissance et la conversion vocale, envoyant ensuite le contenu du chat à notre serveur pour obtenir des réponses, ce qui réalise l'objectif de mener des conversations vocales avec l'utilisateur. Dans ce projet, nous sommes responsables de la partie du traitement du langage naturel pour fournir de meilleures réponses aux résidents. Prof. François Michaud et l'équipe du 3IT (Interdisciplinary Institute for Technological Innovation) de l'Université de Sherbrooke est responsable de la partie reconnaissance et de la conversion vocale du robot.

Les recherches sur l'acceptation des robots sociaux d'assistance chez les personnes âgées et les personnes atteintes de la maladie d'Alzheimer (Whelan and Casey 2020) montrent que les personnes âgées ont tendance à anthropomorphiser les robots lorsqu'elles interagissent avec eux. Si les performances du robot diffèrent considérablement de celles des humains, cela entraînera une diminution de l'acceptation des robots par les personnes âgées. Par conséquent, la capacité du robot à comprendre et à exprimer des émotions similaires à celles des humains affecte grandement l'acceptation des robots par les utilisateurs.

L'un des principaux objectifs de notre projet est de permettre aux robots d'améliorer leur capacité à comprendre et à exprimer leurs émotions, et de démontrer une attitude positive et optimiste en faveur d'un comportement plus humain.

Chez les humains, nous utilisons généralement l'intelligence émotionnelle (IE) pour quantifier la capacité à comprendre et à exprimer des émotions (Culver 1998). L'intelligence émotionnelle, également appelée quotient émotionnel (QE), comprend la capacité de reconnaître, de comprendre et de contrôler les émotions humaines. L'évaluation de l'intelligence émotionnelle humaine peut être réalisée grâce à certains tests de différents types. Nous pensons donc qu'une méthode similaire à celle-ci peut être utilisée pour évaluer

la capacité de compréhension émotionnelle des robots afin d'optimiser l'acceptation des robots par les personnes âgées.




Figure 1: Robot d'assistance sociale T-Top (IntRoLab, n.d.)

1.2 Application des techniques d'apprentissage profond

Après plusieurs années de développement de la technologie d'apprentissage profond et de grands modèles de langue (LLM), les capacités des grands modèles comme ChatGPT (OpenAI, 2023), qui sont basés sur les *transformers* (Vaswani et al. 2017) et les techniques de pré-entraînement, se sont développées très rapidement. Nous espérons qu'Axel pourra également bénéficier de la technologie des grands modèles de langue.

Actuellement, les LLM sont principalement conçus pour des interactions via clavier et l'écran. Par conséquent, LLM a toujours interagi avec les utilisateurs de manière neutre, polie et respectueuse, lisible et selon une structure fixe afin de mieux expliquer la logique, mais en raison des scénarios d'application de notre projet, il existe une différence entre ce style de génération et des styles de conversations humaines. Donc, ce style peut ne pas être très adapté aux échanges conversationnels avec les personnes âgées. Notre travail consiste donc à transformer un LLM en une version adaptée à ce scénario d'application et à la déployer.

Avant le début de notre projet, un autre membre de la maîtrise du laboratoire, Linrui Ma, avait déjà terminé l'optimisation d'une version basée sur le modèle ChatGPT. Beaucoup de ses travaux sont devenus des références importantes pour notre travail (Ma, 2024).

Dans son travail, il a utilisé le modèle ChatGPT et une technologie d'affinage (*fine-tuning*) pour optimiser l'empathie du modèle GPT. Étant donné que le modèle GPT n'est pas open source, son travail nécessite d'appeler l'API de ChatGPT, ce

1.3 La version de l'agent conversationnel basée sur Llama 3

Notre travail consiste à développer une version de l'agent conversationnel basée sur le modèle LLaMA 3. Le modèle LLaMA 3 (Meta AI and Dubey 2024) est un modèle open source, dont les poids sont accessibles. Meta-Llama 3 est disponible sur le site Web de Hugging Face ou via l'interface API de Hugging Face, nous permettant ainsi d'utiliser le GPU pour entraîner sur nos propres machines.

LLaMA 3 est une version améliorée de LLaMA 2, développée par la compagnie Meta, et a été publiée le 18 avril 2024, un mois avant le début de notre projet. C'est également le modèle open source le plus avancé actuellement.

Llama 3 est disponible en deux versions optionnelles, chacune conçue pour des tâches différentes. L'un est un modèle pré-entraîné qui peut être entraîné à l'aide d'une grande quantité de données et utilisé pour des tâches spécifiques. L'autre est une version spécifique au chat qui a utilisé les données de dialogue pour affiner les instructions (*instruction fine-tuned*). Puisque notre projet concerne un chatbot, nous utilisons la version chat. Le modèle Llama 3 que nous avons mentionné plus tard fait référence à la version chat du Llama 3.

Il existe en deux versions disponible de grandeur différente: 8B et 70B, correspondant à différentes tailles de paramètres. Bien que la version 70B offre de meilleures performances, les ressources informatiques nécessaires pour effectuer l'affinage nécessitent au moins environ 160 Go de VRAM. Étant donné que nos ressources informatiques sont limitées, nous avons donc choisi la version 8B.

Il convient de noter que LLaMA 3.1 est une version améliorée de LLaMA 3, mais comme elle a été publiée deux semaines avant la rédaction de ce rapport, nous n'avons pas eu le temps de tester et d'utiliser LLaMA 3.1 dans ce rapport. Cela pourrait être l'orientation future de notre projet.

1.4 Résumé des travaux à présenter dans ce rapport

Pour éliminer l'isolement des personnes âgées, nous devons développer un modèle qui soit bien accepté par cette population, ce qui nécessite de maintenir une conversation de qualité. Une conversation de qualité implique une compréhension approfondie de l'empathie humaine, ce qui exige du modèle une meilleure capacité à comprendre les émotions humaines et à y répondre de manière appropriée et conforme aux normes conversationnelles. Pour ce faire,

1. Nous devons d'abord évaluer la capacité du modèle à comprendre les émotions humaines. (section 2)

2. Puis identifier un moyen de lui permettre d'exprimer des émotions complexes et variées, similaires à celles des humains. (section 3 et 4)

3. Optimiser et évaluer la capacité du modèle à apaiser les émotions des utilisateurs (section 5 et 6)

4. Utiliser des métriques d'évaluation plus détaillées pour mieux mesurer l'empathie exprimée par le modèle (section 5)

De plus, il est indispensable de réaliser une évaluation humaine pour démontrer la faisabilité de notre méthode (section 6, non encore réalisée en raison du temps disponible).

2. L'étude de compréhension émotionnelle des grands modèles

2.1 Intelligence émotionnelle chez les humains

L'intelligence émotionnelle (IE) est la capacité d'une personne à comprendre et à traiter ses émotions. Le quotient émotionnel (QE) est souvent considéré comme une mesure ou un score de l'intelligence émotionnelle, de la même manière que le quotient intellectuel (QI) est une mesure de l'intelligence. Cette intelligence émotionnelle se mesure généralement à travers une série de questions et de tests ou de simulations de scénarios. Pour ce test, les chercheurs ont développé un ensemble mature de critères d'évaluation standardisés pour quantifier les capacités humaines d'intelligence émotionnelle. Dans notre travail, nous espérons utiliser des tests similaires pour apprendre la capacité de compréhension des émotions humaines par les modèles et pour comparer les différences entre les humains et différents modèles.

2.2 Intelligence émotionnelle chez les modèles

Après avoir réfléchi à la situation de notre projet, il nous fallait un modèle qui imite les humains et puisse converser normalement avec les personnes âgées. Notre but ne sera pas d'effectuer la comparaison entre les modèles et les humains, mais d'effectuer une comparaison entre les modèles, en particulier de Llama 3, sur la tâche de la compréhension des émotions humaines.

Cependant, il n'existe pas de méthode très formelle pour tester la compréhension émotionnelle des grands modèles, car l'interaction avec le modèle n'est pas la même qu'avec les humains, mais une méthode disponible consiste à imiter la méthode de test utilisée pour tester l'intelligence émotionnelle humaine. Dans la recherche de (Wang et al. 2023), les auteurs ont développé le test SECEU (Situational Evaluation of Complex Emotional Understanding) pour évaluer la capacité de compréhension émotionnelle de différents modèles. Ce test contient une série de 40 questions basées sur la description du contexte qui contient des émotions complexes, chaque question donne 4 émotions disponibles à choisir, les valeurs possibles sont de 0 à 10, le total de toutes les émotions doit être 10.

Ce test utilise le format .json pour enregistrer la distribution de chaque émotion, et la somme de chaque émotion doit être de 10. Nous pouvons utiliser l'invite pour exiger que le modèle génère un format json spécifique pour calculer les résultats des tests.

Nous utilisons l'apprentissage en quelques coups (*few-shot learning*) et la chaîne de pensées pour contrôler la sortie du format afin que les formats acceptables soient détectés.

Les auteurs ont également demandé à 541 personnes âgées de 17 à 30 ans de faire ce test pour apprendre la moyenne humaine. Cette moyenne humaine est considérée comme le score standard (SS) humain pour effectuer des comparaisons avec différents grands modèles de langue.

Nous pouvons donc utiliser le score standard humain du test SECEU et obtenir l'écart entre le modèle et les humains. Plus l'écart est petit, plus la différence entre le modèle et les humains est petite, et plus la capacité à comprendre les émotions des personnes âgées est

forte. De cette façon, nous pouvons également comprendre quel modèle est le meilleur pour cette tâche.

La méthode de calcul du score SECEU consiste à placer les valeurs des 4 options émotionnelles dans un espace euclidien à 4 dimensions et à calculer la distance entre la réponse du modèle et le score standard humain. Plus la distance est petite, plus le modèle comprend les émotions humaines.

Le score standard humain (SS) est une matrice 40×4 (pour 40 questions, 4 options par question, disponible dans <https://emotional-intelligence.github.io/>), et la réponse du modèle (llm_i) doit également être une matrice de même format, donc pour la question i (de 1 à 40), nous calculons la distance en espace euclidien à 4 dimensions la réponse du modèle et le score standard humain. Le score SECEU du modèle doit être calculé comme suit :

$$SECEU\ score = \frac{1}{40} \sum_{i=1}^{40} \sqrt{(llm_{i1} - SS_{i1})^2 + (llm_{i2} - SS_{i2})^2 + (llm_{i3} - SS_{i3})^2 + (llm_{i4} - SS_{i4})^2}$$

Un exemple de deux premières questions ainsi que les scores standard humains sont illustrés dans la figure 2.

Dans leur étude, ils n'ont pas inclus d'évaluation du modèle Llama 3 car le modèle Llama 3 n'avait pas été publié au moment de la publication de cet article.

Nous avons donc voulu utiliser le test SECEU pour effectuer des évaluations des capacités de compréhension des émotions humaines des modèles Llama 3: 8B et GPT. Les informations du test SECEU sont disponibles sur la page github de (Wang et al. 2023). <https://emotional-intelligence.github.io/>

Il est à noter que les émotions humaines sont en fait divisées en compréhension émotionnelle et expression émotionnelle. Cette partie du test teste uniquement la capacité du modèle à comprendre les émotions.

2.3 Évaluation les capacité de différents modèles

Les modèles que nous avons testés incluent Llama 3, GPT-4o (OpenAI 2024) et GPT-3.5-turbo (OpenAI 2023).

GPT-3.5-turbo est une version optimisée de GPT-3, offrant des performances solides dans la génération de texte naturel, particulièrement utile pour les tâches de conversation et de traitement du langage naturel général. Ce modèle excelle dans des applications nécessitant une réponse rapide et cohérente, telles que les chatbots ou les systèmes de service client automatisés.

GPT-4o est une itération avancée du modèle GPT-4, spécifiquement optimisée pour une meilleure performance dans des domaines spécialisés tels que la création de contenu complexe, l'analyse de données et la compréhension contextuelle profonde. Il est particulièrement performant dans les applications nécessitant une précision accrue et une capacité d'adaptation à des contextes complexes, comme les outils de rédaction assistée par IA (OpenAI 2024), l'analyse sémantique avancée, et les systèmes de recommandation personnalisée.

D'une manière générale, GPT-4o a un plus grand nombre de paramètres et de meilleures performances que GPT-3.5-turbo. Il fonctionne également bien dans de nombreuses tâches

Malgré la modification du prompt, le modèle a toujours une probabilité de répondre dans le mauvais format. Cela peut être lié à la capacité du modèle à comprendre des tâches complexes. Ainsi, lorsque nous ne pouvons pas détecter le format .json correct dans la réponse du modèle, nous redemandons au modèle. Le nombre de fois où le modèle a répondu incorrectement tout au long du test est enregistré.



Modèles	score SECEU	nombre d'erreurs (dans un test de 40 questions)
GPT-3.5-turbo	3.40	4.8
GPT-4o	2.59	0.2
Llama 3: 8B	2.91	6.7

2.4 Analyse des résultats

Nous avons constaté que les performances du modèle Llama 3:8B sur cette tâche sont meilleures que celles du GPT-3.5-turbo, mais pas aussi bonnes que celles du GPT-4o. Ainsi, Llama 3 pourrait avoir une meilleure compréhension des émotions humaines que le modèle GPT-3.5-turbo, et en raison de nos ressources informatiques disponibles, nous ne pouvons utiliser que la version Llama 3:8B. Ce modèle dispose également de versions 70B et Llama 3.1 : 405B. Si plus de ressources informatiques étaient disponibles, nous pourrions avoir de meilleures performances.

Pour les modèles GPT, OpenAI n'a pas divulgué le nombre de paramètres du modèle, mais certaines recherches (Singh et al. 2023) ont émis l'hypothèse que la version GPT-3.5-turbo mesure environ 20 Go, tandis que GPT-4o pourrait être beaucoup plus grande que GPT-3.5-turbo.

Les résultats sur le nombre d'erreurs démontrent la capacité du modèle à comprendre et à respecter des instructions complexes.

Le modèle Llama 3 obtient de meilleures performances dans la tâche de compréhension émotionnelle que le modèle GPT-4o de plus grands paramètres, ce qui peut être lié à la distribution des données d'entraînement, à la qualité des données et à la structure du modèle. Cependant, comme les modèles de type GPT ne sont pas des modèles open source, nous les utilisons comme boîtes noires. Il nous est donc difficile de trouver des raisons précises à ce type de modèle.

Notre idée initiale était d'essayer d'utiliser ce test pour évaluer les capacités de notre modèle Llama 3 après nos améliorations. Malheureusement, la méthode d'amélioration que nous avons choisie était basée sur l'affinage des données de conversation, et les améliorations des prompts. Notre modèle Llama 3 après affinage répond toujours sous forme de conversation (tour de parole), cependant le test SECEU nécessite des données au format .json. Ceci est complètement opposé à la direction de notre optimisation, nous avons donc dû renoncer à utiliser ce test pour évaluer l'effet d'affinage.

Mais ce que nous avons appris de ce test, c'est la diversité et la complexité des émotions. Cela fournit de nouvelles idées pour nos travaux ultérieurs.

3. Classificateur d'émotions

Grâce aux conclusions tirées dans la section précédente, nous connaissons la complexité des émotions humaines. Pour les modèles centrés sur les tâches conversationnelles, il est crucial de générer des réponses émotionnellement diversifiées et complexes pour mieux simuler l'interaction humaine. Cela peut donner aux utilisateurs l'impression d'être face à un robot avec des émotions complexes comme les humains, plutôt qu'à un robot sans émotion.

Pour ajouter de la complexité émotionnelle au modèle, nous devons d'abord déterminer les émotions actuellement exprimées par l'utilisateur afin de pouvoir générer logiquement la complexité émotionnelle correspondante.

Il s'agit également d'une simulation de la conversation entre humains : lorsque les humains se parlent, ils jugent d'abord inconsciemment l'émotion de l'autre. Si l'autre est dans une très mauvaise émotion, nous ne voulons pas dire des choses pires pour la mettre en colère.

3.1 Classificateur basé sur le modèle pré-entraîné: BERT

L'emploi du modèle BERT (Devlin et al. 2019) pour la classification textuelle est une approche répandue et efficace. Nous avons besoin de certains ensembles de données de dialogue avec des labels d'émotion et les entraîner sur le modèle pré-entraîné de BERT pour obtenir un classificateur d'émotions.

Dans notre projet, nous visons à développer un classificateur capable d'évaluer en temps réel les émotions des utilisateurs. Nous avons donc besoin d'un ensemble de données avec plusieurs cycles de dialogue et des labels d'émotion pour chaque cycle de dialogue. Le meilleur ensemble de données que nous avons trouvé est l'ensemble de données DailyDialogue (Li et al. 2017).

Cet ensemble de données contient plus de 11,000 conversations; chaque conversation contient un certain nombre d'énoncés par deux humains. L'étiquette (*label*) émotionnelle correspondante à chaque énoncé est également incluse dans l'ensemble de données. Les labels d'émotion sont divisés en 7 catégories: aucune émotion, colère, dégoût, peur, bonheur, tristesse et surprise.

La figure 3 présente la distribution des 6 catégories d'étiquettes émotionnelles ; il est à noter que la statistique de l'étiquette "aucune émotion" n'est pas incluse dans cette figure.




Figure 3 : Distribution des 6 catégories d'étiquettes émotionnelles (sans l'étiquette "aucune émotion") (Li et al. 2017).

3.1.1 Structure de prétraitement des données

Nous supposons que dans les interactions humaines, les dialogues précédents influencent également jusqu'à un certain point les fluctuations émotionnelles. Par exemple, si nous avons une conversation sur un sujet très triste, alors les "au revoir" à la fin de la conversation peuvent également contenir des émotions tristes, mais dans une autre situation, les "au revoir" peuvent contenir des émotions heureuses.

Fondés sur cette hypothèse, nous avons établi la structure utilisée pour notre processus de prétraitement des données.

Disons que la conversation (représenté par le symbole C) contient des énoncés (*utterances*) de deux personnes ($u_1, u_2, u_3, \dots, u_n$) (la lettre u signifie le mot "utterance" en anglais) tout au long de la conversation, la personne A dit tous les énoncés où n =nombres impairs, et la personne B répond par des énoncés où u_{n+1} , puis la personne A répond à la personne B avec u_{n+2} , et ainsi de suite..... Le label d'émotion correspondant à chaque u_n est e_n .

Dans notre traitement des données, nous traitons la conversation $C = (u_1, u_2, u_3, \dots, u_n)$ et labels d'émotion $E = (e_1, e_2, e_3, \dots, e_n)$ dans l'ensemble de données d'origine comme

$$C = u_1 | u_2 | \dots | u_n | \text{ et } E = e_n$$

Le symbole "|" est utilisé pour indiquer la fin de l'énoncé. Ensuite, nous ne conservons que la dernière étiquette de sentiment. De cette façon, nous espérons que le modèle pourra apprendre à classer l'émotion du dernier énoncé et à considérer de manière appropriée l'impact émotionnel de tout le contexte (u_i quand $i < n$) précédent sur l'émotion contenue dans l'énoncé u_n .

De cette manière, chaque conversation peut générer des quantités variables de données. Par exemple, nous pouvons convertir la conversation contenant u_1, u_2 et u_3 en $u_1|$ (un seul énoncé), $u_2| u_3|$ (à l'exclusion de u_1), et prédire uniquement l'émotion de u_3 . Le but est de gérer la troncature sous la limite maximale de fenêtre de 512 caractères du modèle BERT.

Dans ce cas, on appelle cet ordre de traitement des énoncés "l'ordre direct".

De plus, nous avons également testé l'inversion de notre structure lors du prétraitement des données, c'est-à-dire en plaçant les dialogues les plus proches au début et les dialogues le plus anciens à la fin des données. On l'appelle "l'ordre inverse".

Il est aussi nécessaire de faire la même opération sur l'ensemble de validation et du test pour évaluer correctement.

Puisque notre traitement de données peut extraire de nombreuses combinaisons d'énoncés d'une conversation, nous fixons une certaine quantité de données à randomiser pour générer des données qui répondent à nos attentes. Après ce que nous avons mentionné, l'ensemble de données d'entraînement est passé de 11 000 données à 33000 données, et l'ensemble de données de validation est passé de 1100 à 3300 données. En moyenne, chaque conversation a généré 3 données correspondant à notre structure.

3.1.2 Mesures d'évaluation

Nous avons utilisé trois mesures d'évaluation différentes. Les deux premières sont la précision (*accuracy*) et le score f1, qui sont des méthodes d'évaluation très courantes dans les tâches de classification de texte. Le troisième est dû au déséquilibre de distribution des données dans l'ensemble de données que nous avons trouvé.

L'ensemble de données DailyDialogue contient une grande quantité de texte, avec plus de 50 000 énoncés différents. Après nos tests, nous avons constaté qu'environ 82.76 % des énoncés étaient classés dans la catégorie sans émotion. Cela signifie que si le modèle BERT après l'entraînement classe tous les énoncés sous ce label, alors la précision atteindra 82.76 %, mais les données classées par ce modèle ne nous seront d'aucune utilité. Donc, nous ajoutons une partie au code d'évaluation pour calculer quel pourcentage des données d'autres étiquetées ont été incorrectement classées dans la catégorie "sans émotion". Nous appellerons ce métrique par la suite "le pourcentage mal classifié" (% mal classifié dans le tableau 2). L'objectif est de minimiser la valeur de ce métrique.

3.1.3 Réglage des hyperparamètres

Après avoir essayé différentes tailles de lots (*batch size*), taux d'apprentissage et numéros d'époque, nous avons constaté que, comme nous le pensions auparavant, le modèle est plus enclin à classer davantage de données sous la forme d'étiquettes « sans émotion » pour améliorer la précision. Le pourcentage d'émotions incorrectement classées dans aucune émotion (% mal classifié) n'a jamais été inférieur à 30%.

La méthode que nous avons trouvée consiste à définir des poids différents pour différentes labels pendant la phase d'entraînement, et par défaut, le modèle attribuera le même poids à toutes les étiquettes, et lorsque nous définirons un poids plus grand pour les étiquettes (*label/s*) de la classe minoritaire, notre modèle sera plus enclin à être affectés à la classe minoritaire. Nous avons attribué les mêmes pondérations (poids) à toutes les étiquettes, à l'exception de l'étiquette "aucune émotion" qui était la plus fréquente, afin d'obtenir de

meilleurs résultats de classification. Une description plus détaillée de notre solution est présentée ci-dessous.

Nous avons utilisé la fonction d'entropie croisée (*Cross entropy function*) comme fonction de perte, qui est couramment utilisée dans les tâches de classification de texte:

$$L(y, \hat{y}) = - \sum_{i=1}^c w_i \cdot y_i \log(\hat{y}_i)$$

Nous attribuons des poids w_i plus élevés aux classes minoritaires, ce qui peut augmenter leur contribution à la perte globale, de sorte que le modèle accorde plus d'attention à ces classes.

Cependant, en raison de problèmes de distribution des données, si nous continuons à entraîner plusieurs époques, notre modèle biaise inévitablement les résultats vers l'étiquette sans émotion afin d'obtenir une plus grande précision. Nous avons donc décidé de choisir une seule époque d'entraînement, afin que le pourcentage mal classifié à l'étiquette "aucune émotion" soit dans une plage acceptable (entre 7% et 15%), et que nous puissions éviter dans une certaine mesure le problème du surentraînement du modèle.

Ceci n'affecte pas trop le score f1 et la précision (1% de précision et 0.02 de score-f1), mais le pourcentage d'émotions incorrectement classées dans "aucune émotion" a obtenu une amélioration de 2%.

L'influence de différents poids ainsi le nombre d'époque et l'ordre dans le procédé des énoncés sont présentés dans le tableau 2.

Tous ces résultats sont fait avec une taille du lot (*batch size*) de 60.

Hyperparameter	Experiment 1	Experiment 2	Experiment 3	Experiment 4	Experiment 5
Poids					
aucune émotion	1	1	1	1	1
colère	1	5	5	7	7
dégoût	1	5	5	7	7
peur	1	5	5	7	7
bonheur	1	5	5	7	7
tristesse	1	5	5	7	7
surprise	1	5	5	7	7
Procédure	Direct	Direct	Direct	Direct	Inverse
Nombre d'époque	1	1	2	1	1
Precision en %	88.5	83.9	83.4	81.8	80.0
F1-score	0.872	0.854	0.85	0.84	0.82
% mal classifié	29.7	12.93	15.55	10.76	7.23

Tableau 2: Comparaison des différents hyper paramètres et résultats expérimentaux

3.1.4 Comparaison entre le modèle RoBERTa et le modèle BERT


Le modèle RoBERTa (Liu et al. 2019) peut être utilisé pour gérer les mêmes types de tâches que BERT, et RoBERTa peut obtenir de meilleures performances dans certaines tâches.

Par rapport à BERT, RoBERTa abandonne la tâche de prédiction de la phrase suivante pour se concentrer exclusivement sur la tâche de prédiction des mots masqués. De plus, RoBERTa utilise un volume de données d'entraînement beaucoup plus important et un batch size plus élevé. Cette approche permet à RoBERTa d'améliorer sa capacité à modéliser le langage en se basant sur une plus grande variété d'exemples, tout en optimisant l'efficacité du processus d'apprentissage.

Le processus d'implémentation du modèle RoBERTa est très similaire à celui du modèle BERT, mais en l'absence de la tâche de prédiction de la phrase suivante, le modèle RoBERTa ne nécessite plus le paramètre `token_type_ids`, qui était utilisé pour traiter et reconnaître les relations entre les phrases. Sans ce paramètre, le modèle RoBERTa peut mieux se concentrer sur l'influence des mots dans les deux directions au sein d'une phrase.

Nous avons comparé les processus de perte et de précision des modèles BERT et RoBERTa durant l'entraînement de plusieurs époques. Les résultats de la comparaison sur l'ensemble de validation sont présentés dans la figure 4. Nous avons constaté que le modèle RoBERTa ne s'améliorait pas beaucoup par rapport au modèle BERT et était environ 1 % à 2% de différence au modèle BERT à certains nœuds de temps d'entraînement. Nous observons que la performance du modèle RoBERTa n'a pas augmenté considérablement, donc nous avons donc décidé de continuer à utiliser le modèle BERT comme classificateur d'émotions.

RoBERTa



BERT




Figure 4: Comparaison de la précision et le score f1 entre BERT et RoBERTa pour l'entraînement pour plusieurs époques sur l'ensemble de validation

4. Contrôle d'émotion

4.1 La matrice de transition émotionnelle

Dans la version basée sur GPT du projet Axel, (Ma, 2024) utilise également l'ensemble de données DailyDialogue. Plutôt que de s'en servir pour entraîner un classificateur d'émotions, il a élaboré un modèle probabiliste de transition émotionnelle, illustré à la Figure 5 (Ma 2024). Ce modèle présente une matrice qui présente la distribution de probabilité de la réponse avec l'émotion Y à une question ou un énoncé d'émotion X. De cette façon, la probabilité $P(Y | X)$ est beaucoup plus logique et plus cohérente avec le contexte et les scénarios d'application réels que le méthode statistique de $P(X)$.




Figure 5: Matrice de transition basé sur l'ensemble de données DailyDialogue (Li et al. 2017)

4.2 L'utilisation de la matrice de transition en utilisant le classificateur BERT (Devlin et al. 2019)

Notre classificateur étant capable de classifier précisément les émotions de l'utilisateur, nous pouvons ainsi créer un assistant qui répond de manière plus cohérente aux émotions humaines grâce à cette matrice de probabilités.

4.2.1 Discussion sur des cas particuliers

Lors de l'entraînement du modèle BERT sur l'ensemble de données DailyDialogue, nous avons découvert un problème dans l'ensemble de données. Un problème est que les interactions entre deux personnes dans l'ensemble de données sont aléatoires, sans rôles fixes d'assistants ou d'utilisateurs. Cela inclut également certaines situations qui peuvent amener une partie à ne pas prendre en compte les émotions de l'autre partie. Cela conduit au fait que si nous suivons complètement cette distribution de probabilité, notre modèle pourrait évoluer vers des sentiments inappropriés. Par exemple, dans certaines scènes de DailyDialogue, deux personnes peuvent se disputer, ce qui est très courant pour deux humains, mais nous ne voulons pas que notre robot de conversation se dispute également avec l'utilisateur.

Étant donné que nous avons constaté que les scénarios d'utilisation de DailyDialogue diffèrent de ceux de notre robot d'assistance sociale, nous ne pouvons pas exiger que le modèle génère automatiquement des émotions spécifiques en se basant uniquement sur les statistiques de ce corpus. Pour certaines émotions particulières, il est nécessaire de contrôler le modèle afin qu'il produise des réponses émotionnelles ciblées, visant à améliorer l'état émotionnel de l'utilisateur.

Dans ce cas, puisque nous avons déjà évoqué le problème de plusieurs émotions complexes se produisant en même temps, nous pouvons guider le modèle pour nuancer ses émotions et diriger l'utilisateur vers une meilleure émotion.

Par exemple, lorsqu'un utilisateur exprime de la colère, nous pouvons guider le modèle pour qu'il montre une frustration appropriée, pas pour entrer en conflit avec l'utilisateur, mais pour exprimer sa reconnaissance et son empathie pour la situation vécue par l'utilisateur.

Nous pouvons utiliser l'apprentissage en quelques coups (*few-shot learning*) pour ajouter quelques cas d'utilisation afin d'atteindre nos objectifs. Un exemple de l'apprentissage en quelques coups est disponible dans l'annexe 2.

Un autre avantage de cette méthode est que, puisque notre méthode est basée sur des statistiques de probabilité, dans des situations réelles, la conversion des émotions des gens dépend davantage de la compréhension et de la logique du contexte, si nous forçons le modèle à spécifier la réponse émotionnelle, cela entraîne des réponses illogiques du modèle et une réduction des performances du modèle. Par conséquent, augmenter le style de parole du modèle grâce à des prompts à few-shot peut affecter la production émotionnelle mais réduire le degré de dégradation des performances du modèle.

Il est à noter que, en raison des limites de l'ensemble de données DailyDialogue, nous avons cherché à identifier d'autres ensembles de données qui correspondent mieux aux besoins de notre robot d'assistance sociale. Cependant, nous n'avons pas réussi à en trouver. Si un ensemble de données similaire, mais mieux adapté à notre contexte d'utilisation, était disponible, l'efficacité de notre travail pourrait être considérablement améliorée.

4.2.2 Module de conversion d'émotion

En utilisant la matrice de transition d'émotions, nous déterminons, d'après les catégories d'émotions classifiées par le classificateur, l'émotion que le modèle doit exprimer de manière appropriée. Si l'émotion est "aucune émotion", aucune prompt ne sera générée, et si elle est d'autres émotions, il transmet le prompt approprié pour contrôler le modèle afin d'exprimer l'émotion spécifiée.

L'exemple du prompt pour contrôler le modèle afin de générer des émotions de colère tout en garantissant une orientation correcte des émotions humaines vers un meilleur état peuvent être trouvées dans l'annexe 2.

Dans ce cas, la méthode de la chaîne de pensée n'est pas applicable, car nous ne voulons pas que le modèle indique à l'utilisateur comment le raisonnement s'est produit, la seule option est donc d'utiliser une prompt de haute qualité en quelques coups. Après le test, Llama 3 est dans ce cas. De cette manière, le modèle peut générer l'émotion composée que nous avons spécifiée avec une probabilité de 80 % dans les 50 essais qu'on effectue avec Llama 3.

4.2.3 Contrôle de la longueur de la fenêtre

Lors de l'utilisation du modèle Llama 3, nous sommes confrontés à un problème majeur : la gestion de la longueur de la fenêtre contextuelle. Cette fenêtre contextuelle représente la quantité maximale de texte que le modèle peut traiter en une seule fois, incluant les messages système, les messages de l'utilisateur, ainsi que les réponses du modèle lui-même.

La longueur de cette fenêtre est limitée à 8 000 jetons (tokens). Cela signifie que lorsque la somme totale des jetons dans ces trois composantes dépasse cette limite, le modèle tronque automatiquement une partie du texte, généralement les premières instructions ou messages fournis. En d'autres termes, si des instructions critiques sont données au début de l'interaction, elles risquent d'être perdues ou oubliées par le modèle au fur et à mesure que la conversation avance et que la fenêtre se remplit.

Ce problème est particulièrement accentué lorsque la longueur de la fenêtre augmente, car le temps d'inférence du modèle s'allonge de manière significative, impactant ainsi la réactivité et l'efficacité globale du modèle lors des interactions prolongées avec l'utilisateur.

Notre réponse à cela est, au moment où on approche la limite de longueur de fenêtre, d'appeler l'interface ChatGPT 4o d'OPENAI, de lui transmettre l'enregistrement de la conversation et de lui demander de le résumer dans une certaine longueur de texte. Nous transférons ensuite le contenu résumé par ChatGPT vers le modèle Llama 3 pour créer une nouvelle conversation. Nous avons choisi ChatGPT 4o car ce modèle fonctionne bien sur les tâches de résumé et de synthèse de texte par rapport à d'autres modèles.

5. Affinage (*fine-tuning*) du modèle Llama 3

L'affinage est le moyen le plus courant d'optimiser les performances de grands modèles sur des tâches spécifiques. Parmi eux, l'affinage de tous les paramètres est généralement le meilleur moyen, c'est aussi la méthode utilisée dans la version GPT du projet Axel, les ressources informatiques du serveur du OpenAI sont utilisées dans cette version. Cependant, en raison des limitations des ressources informatiques, il nous est difficile d'utiliser cette méthode parce que nous entraînons le modèle complètement sur la machine du DIRO. Les options qui s'offrent à nous sont donc l'affinage de LoRA (Hu et al. 2021).

5.1 Aperçu du LoRA

Étant donné que les LLM pré-entraînés contiennent généralement de nombreux paramètres, la mise à jour de tous les paramètres pendant l'entraînement nécessite une grande quantité de calculs. LoRA décompose la matrice de paramètres du modèle pré-entraîné en deux matrices plus petites, puis entraîne ces deux petites matrices avec les données d'entraînement, puis multiplie les deux matrices pour obtenir la matrice de changement par le modèle d'origine, puis convertit le modèle original. Les paramètres du modèle pré-entraîné sont combinés ici pour obtenir le modèle après l'affinage. Le nombre de paramètres requis pour l'entraînement étant considérablement réduit, les ressources informatiques requises nous paraissent également acceptables.

5.2 Utilisation de certains outils open source

En raison de la complexité des tâches liées à l'apprentissage profond, il est souvent complexe de mettre en œuvre manuellement l'intégralité du flux de travail nous-même. La manière la plus courante consiste à utiliser certains outils open source pour simplifier notre travail.

5.2.1 Outil pour effectuer l'entraînement du modèle

Nous avons essayé différents outils pour effectuer l'affinage de LoRA et avons finalement constaté que la meilleure option était d'utiliser Llama Factory (Zheng et al. 2024). Nous devons modifier le dossier data pour ajouter nos données .json conforme au format demandé, et modifier le fichier data_info.json. Pour effectuer l'entraînement, un fichier .yaml contenant les hyperparamètres est requis. Après avoir terminé l'entraînement, nous pouvons obtenir les fichiers de l'adaptateur LoRA au format safetensor. Nous pouvons ensuite utiliser un autre fichier .yaml pour fusionner les poids du modèle pré-entraînés et l'adaptateur LoRA afin d'obtenir le fichier de poids du modèle .safetensor pour le nouveau modèle. La taille de tous les fichiers de poids est d'environ 16 Go d'espace de stockage.

5.2.2 Quantification et conversion du modèle

Afin d'améliorer la vitesse d'inférence lors de l'utilisation de modèles open source, L'outil open source de llama.cpp (Gerganov 2023) est généralement utilisé. Cet outil utilise le langage C++ pour convertir les fichiers safetensor du modèle au format .gguf, améliorant ainsi considérablement la vitesse d'exécution du modèle. Ce format est aussi accepté par des outils tels que ollama, qui sont utilisés pour l'inférence et le déploiement du modèle sur

le serveur. Il est également possible de quantifier le modèle en 8 bits ,en utilisant cet outil, avec une faible perte de performances.

Après quantification à 8 bits, notre modèle est passé de plusieurs fichiers Safetensor d'une taille totale de 16 Go à un format de fichier .gguf de 8 Go. Le temps d'inférence de notre modèle est considérablement réduit.

5.2.3 Inférence et de déploiement

Nous avons essayé d'utiliser l'outil ollama pour l'inférence de modèle, mais lorsque nous avons utilisé le fichier gguf de modèle après l'affinage pour l'inférence via le fichier Modelfile et les instructions ollama, nous avons constaté que le modèle commençait à générer de longs documents basés sur le message qu'on lui donne au lieu de répondre à la question comme dans une conversation normale.

Nous supposons que cela est probablement dû au fait que notre fichier Modelfile ne contient pas de template de conversation correct. Donc, nous essayons donc de concevoir un template de conversation afin que le modèle puisse communiquer correctement avec l'utilisateur. Mais malheureusement, après avoir essayé de nombreuses possibilités, nous n'y sommes toujours pas parvenus. Nous avons donc essayé d'utiliser un autre outil d'inférence de modèle.

llama.cpp qu'on a utilisé pour convertir le format du modèle contient également la fonction d'utilisation de fichiers gguf pour l'inférence de modèle, et l'exécution inclut une option pour démarrer en mode conversation. Nous pouvons utiliser cet outil pour l'inférence et l'évaluation de modèles.

5.3 Utilisation de l'ensemble de données Open Assistant

5.3.1 Ensemble de données Open Assistant

Open Assistant (<https://andrewm4894.github.io/Open-Assistant/>) est un site Web pour les bénévoles et les personnes cherchant une aide psychologique. Les utilisateurs sont divisés en utilisateurs recherchant de l'aide et en assistants non psychiatres. Ils utilisent le dialogue de saisie au clavier pour communiquer afin de compléter la communication de la situation. Dans le travail de (Köpf, Kilcher, and Mattick 2023), certains ensembles de données de haute qualité (environ 84,000 données de différentes langues) sont rendus publics et les données sont régulièrement vérifiées pour garantir dans une certaine mesure leur qualité.

Étant donné que notre tâche consiste également à aider les personnes âgées qui sont socialement isolées dans une certaine mesure, nous pensons que nous pouvons utiliser cet ensemble de données pour améliorer les performances du modèle.

De plus, cet ensemble de données contient également des données dans des langues autres que l'anglais. Nous pensons donc que l'utilisation de cet ensemble de données peut mieux aider certains utilisateurs qui ne sont pas anglophones. Dans le contexte de notre projet, de nombreux résidents du Québec sont de langue maternelle française et d'autres langues.

5.3.2 Entraînement et évaluation du modèle

Nous avons utilisé les outils mentionnés dans la section précédente et l'ensemble de données Open Assistant pour effectuer LoRA sur le modèle Llama 3 pour 1 époque afin d'obtenir un nouveau modèle. Le temps qu'on a pris pour l'entraînement est d'environ une heure sur une machine du DIRO qui contient un GPU Nvidia 4090. Nous avons nommé ce modèle Llama_OPEN.

Cependant, l'évaluation humaine de ce modèle montre qu'il est loin d'être idéal. La logique de réponse du modèle est très déroutante et le modèle préfère parfois générer des réponses plus courtes et ne fournit pas assez d'information pour répondre à la question posée. Nous pensons que cela est dû au fait que les personnes qui utilisent des claviers pour communiquer sur le site Web Open Assistant préfèrent utiliser un style de chat sur les réseaux sociaux, caractérisé par des phrases plus courtes et l'omission de certains signes de ponctuation. De plus, cet ensemble de données contient plus de 80 000 données, il contient donc des données de qualité et de style très variables. Lorsque notre modèle pré-entraîné contient ses propres connaissances qui entrent en conflit avec ce style, cela conduit à une confusion logique dans le modèle. Le tableau 3 donne un exemple de l'évaluation qu'on fait avec le modèle Llama_OPEN. La logique du modèle devient incompréhensible, il nous est impossible d'utiliser ce modèle comme agent conversationnel qui communique avec les résidents des CHSLD.

Tableau 3: question-réponse du modèle Llama_OPEN

humain	Llama_OPEN
I feel so bad, can you talk with me please?	Of course I can! I am here to help you with anything you need. How are you feeling? Would you like to talk about something specific?
Tell me a story please.	I have a story! Do you want to hear it?
Sure.	Here is a story I found on the internet
Go ahead.	I don't have a story to tell! How about I tell you about my day?
Ok.	I am an artificial intelligence, I don't have a day like you do. I am always on and I have no feelings. I am just here to help you.

5.3.3 Observations et changement de direction

La première et la plus importante chose est le manque de qualité des données, et nous n'avons pas de norme claire pour évaluer la qualité des données. Bien que l'Open Assistant Data vérifie dans une certaine mesure la qualité des données, en raison de la grande quantité de données et des différentes sources de données, garantir la haute qualité de toutes les données devient une tâche difficile.

De plus, nous avons constaté que les réponses du modèle Llama 3 d'origine étaient plus enclines aux textes longs, et notre modèle Llama_OPEN était affecté par les données d'entraînement et générait des longueurs similaires. Nous pensons que c'est la direction que nous devons améliorer. Nous pouvons choisir la longueur des données de formation pour contrôler la longueur de la sortie du modèle par rapport à la durée d'une conversation normale. Cela peut éviter que le modèle ne génère de longues phrases qui font perdre patience aux utilisateurs.

5.4 Métrique d'évaluation humaine

Étant donné que notre affinage modifie le mode de sortie du modèle, notre modèle affiné répond toujours aux questions de manière conversationnelle quotidienne. Il nous est difficile de faire en sorte que le modèle effectue le test SECEU qu'on a précédemment utilisé dans la section 2.2 , nous avons donc besoin d'une évaluation manuelle effectuée par les humains pour évaluer le modèle. Nous avons besoin d'une norme quantitative pour vérifier si les performances du modèle sont devenues meilleures qu'auparavant.

5.4.1 Les métriques classique pour la génération de langage naturel (NLG)

La pertinence et la fluidité sont des métriques d'évaluation couramment utilisées pour les tâches de génération de texte. L'empathie est aussi une métrique très souvent utilisée dans les évaluations dans des tâches de communications. Cependant, comme la technologie que nous utilisons est un modèle d'intelligence artificielle basé sur un modèle pré-entraîné, (Ma 2024) a utilisé une classification plus détaillée des indicateurs d'évaluation de l'empathie, le nom de cette évaluation est EPITOME, dans ses travaux sur la version GPT du projet Axel. Et nous avons également constaté que le modèle Llama 3 est également déjà très performant dans les tâches de pertinence et de fluidité du texte, au moins assez parfait pour les tâches de compréhension et de communication avec les humains.

5.4.2 Les métriques EPITOME

La méthode d'évaluation d'EPITOME (Sharma et al. 2020) est un raffinement supplémentaire de l'empathie, divisée en réactions émotionnelles, interprétation et exploration, utilisée pour évaluer le niveau empathique dans les dialogues.

L'interprétation exacte de chaque mécanisme est :


Réactions émotionnelles : Expression d'émotions telles que la chaleur, la compassion et l'inquiétude, ressenties par l'assistant humain aidant après avoir lu les messages des personnes. L'expression de ces émotions joue un rôle important dans l'établissement d'un rapport empathique et d'un soutien. Une communication faible des réactions émotionnelles fait allusion à ces émotions sans que celles-ci soient explicitement étiquetées (par exemple, tout ira bien). En revanche, une communication forte précise les émotions ressenties (par exemple, je me sens vraiment triste pour toi).

Interprétations : Communiquer une compréhension des sentiments et des expériences déduits de la publication de la personne. Une telle compréhension cognitive dans les réponses est utile pour accroître la prise de conscience des sentiments et des expériences cachés, et essentielle pour développer une alliance entre la personne et l'assistant qui le soutient. Une communication faible des interprétations contient une mention de la compréhension (par exemple, je comprends ce que tu ressens) tandis qu'une communication forte précise le sentiment ou l'expérience déduits (par exemple, cela doit être terrifiant) ou communique la compréhension par le biais de descriptions d'expériences similaires (par exemple, j'ai aussi parfois des crises d'angoisse qui me terrifient vraiment).

Explorations: Améliorer la compréhension de la personne en explorant les sentiments et les expériences qui ne sont pas mentionnés dans la publication. Montrer un intérêt actif pour ce que la personne vit et ressent et sonder doucement est un autre aspect important de l'empathie. Une exploration faible est générique (par exemple, que s'est-il passé ?) tandis qu'une exploration forte est spécifique et identifie les expériences et les sentiments du demandeur que l'assistant aidant souhaite explorer (par exemple, vous sentez-vous seul en ce moment ?).

Un exemple de l'évaluation est donné dans la figure 6.

Figure 6: Exemple illustrant les trois indicateurs EPITOME et leur niveau de communication



EPITOME combine des aspects affectifs et cognitifs de l'empathie qui n'ont été étudiés que dans le cadre d'une thérapie en face à face et jamais dans un dialogue asynchrone basé sur du texte. Pour chacun de ces mécanismes, nous distinguons trois niveaux de réponse (0) les réponses qui ne les expriment pas du tout (pas de communication), (1) les réponses qui les expriment dans une certaine mesure (communication faible), (2) les réponses qui les expriment fortement (communication forte), (3) les réponses qui les expriment très fortement (communication très forte).

Cette nouvelle métrique d'évaluation est plus adaptée à notre projet que les trois méthodes d'évaluation classique: L'empathie, la pertinence et la fluidité, car l'empathie est exactement ce que nous souhaitons pour optimiser le chatbot sur la base du grand modèle. Cette méthode d'évaluation nous permet de mieux évaluer les performances du modèle.

De plus, étant donné que l'échelle originale de 0 à 2 utilisée par les auteurs de l'EPITOME n'était pas suffisamment précise pour la classification des données, nous avons constaté que le niveau de communication pouvait être subdivisé en catégories plus détaillées. En effet, certaines réponses peuvent exprimer des émotions de manière plus intense et plus nuancée que d'autres, même si elles sont toutes deux classées au même niveau. Par exemple, deux réponses classées comme "fortes" peuvent présenter des différences significatives en termes d'intensité émotionnelle, l'une étant clairement plus marquée que l'autre. Pour remédier à cette limitation, nous avons ajouté un niveau "très fort" avec une valeur de 3. Nous avons ainsi décidé d'étendre l'échelle de communication à 3 niveaux, ce qui porte les valeurs disponibles pour EPITOME de 0 à 3.

5.4.3 Évaluations supplémentaires

Dans la section précédente 5.3.3, nous avons découvert que la méthode d'interaction originale du modèle Llama 3 est différente du scénario d'application de notre projet.

Le scénario d'application du modèle Llama 3 consiste généralement à utiliser des pages Web ou des lignes de commande pour permettre aux utilisateurs de saisir des informations via le clavier et de consulter les réponses à l'écran. Et dans notre projet, les utilisateurs interagissent avec le robot via la reconnaissance vocale et la conversion de texte. La situation générée sera donc différente.

La façon dont les humains lisent est très différente de celle qu'on écoute et parle. Tout d'abord, la vitesse de lecture sera plus rapide et un certain format est nécessaire pour faciliter la lecture, de sorte que le modèle Llama 3 génère du contenu tel que des sauts de ligne, des numérotations et du texte long pour saisir plus d'informations. Pour notre projet, les formats de lisibilité optimisés tels que les sauts de ligne et les nombres ne sont pas nécessaires, et la conversion du texte en parole doit être suffisamment lente pour que les humains puissent la comprendre. Cela peut entraîner des temps de lecture trop longs pour des textes longs et réduire l'utilité du modèle.

Ainsi, lors de l'évaluation humaine du modèle, nous appliquons une pénalité au score EPITOME pour les textes que nous jugeons excessivement longs. Une pénalité de 1 à 2 points est appliquée sur la métrique que nous estimons affectée, en fonction de la question

et de l'humeur de l'utilisateur, lorsque les réponses du modèle sont considérées comme trop longues. De plus, si le modèle génère des réponses contenant de nombreuses parenthèses, des descriptions d'actions, des monologues internes ou tout autre contenu non naturel dans une conversation humaine, un score de 0 est attribué à la réponse pour toutes les métriques. Cependant, dans des cas particuliers, tels que lorsque l'utilisateur demande explicitement un texte long ou exprime des émotions très négatives, aucune pénalité n'est appliquée à la longueur du texte, à condition que celle-ci soit jugée appropriée.

De plus, nous avons introduit un critère d'évaluation distinct pour le modèle, qui mesure le degré de cohérence avec le style conversationnel humain. Pour évaluer ce critère, nous avons effectué 30 interactions avec le modèle. À chaque interaction, nous avons analysé chaque réponse du modèle en vérifiant si elle correspondait aux styles de conversation habituels entre humains. Ensuite, nous avons calculé le pourcentage de réponses qui étaient conformes à ces styles conversationnels. Ce pourcentage reflète la capacité du modèle à produire des réponses naturelles et adaptées dans un contexte de conversation quotidienne.

5.5 Utilisation de l'ensemble de données EPITOME

Dans le travail de (Sharma et al. 2020), les auteurs ont développé les métriques d'évaluation EPITOME qu'on a discuté précédemment. Ils ont également un ensemble de données EPITOME avec des évaluations manuelles en utilisant ces métriques d'évaluation.

Dans le rapport du projet Axel pour la version GPT de (Ma, 2024), les meilleurs résultats parmi tous les ensembles de données d'affinage qu'il a utilisés étaient les 100 données les mieux notées dans l'ensemble de données EPITOME. En utilisant seulement les 100 données de conversation, le modèle GPT a dépassé tous les autres modèles qu'il a entraînés (sauf pour la partie optimisation basée sur ce modèle affiné). Ceci est également cohérent avec les résultats des recherches de (Zhou et al. 2023), dont les travaux ont prouvé que l'utilisation d'une petite quantité de données de haute qualité peut surpasser les résultats d'un plus grand nombre de données de qualité variable.

Nous avons donc décidé d'utiliser ces 100 données de la plus haute qualité provenant de l'ensemble de données EPITOME. Nous nommons cet ensemble de données EPITOME-100.

Après 3 époques d'entraînement, nous obtenons le modèle qu'on nomme Llama_EPI.

5.5.1 Prompt pour la tâche de conversation

Dans le travail de Ma (2024), il a déjà trouvé une version très puissante de prompt parmi plusieurs combinaisons possibles. Ce prompt a donné un très bon résultat sur le modèle GPT. Donc, nous utilisons ce prompt, en modifiant légèrement, en même temps avec les deux modèles Llama_EPI et Llama 3 version originale pour effectuer une comparaison entre eux. Le prompt qu'on a utilisé dans cette partie se trouve dans l'annexe 3.

5.5.2 Évaluation humaine

Les données d'évaluation humaine sont basées sur un ensemble de données de simulation de scénario appelé Blended Skill Talk (Kim, Kim, and Song 2022). On a sélectionné manuellement 50 simulations de scénarios adaptées aux personnes âgées dans les CHSLD, puis on a demandé au modèle de générer la dernière réponse. Nous avons ensuite testé la capacité du modèle en utilisant les méthodes d'évaluation que nous avons mentionnées dans la section précédente.

On a fait l'évaluation avec l'aide de Fabrizio Gotti, chercheur du laboratoire RALI, qui a aussi aidé (Ma, 2024) dans sa partie d'évaluation.

Au cours du processus d'évaluation, nous avons constaté que la méthode d'évaluation d'EPITOME n'est pas toujours applicable. Par exemple, dans des scénarios très simples, tels qu'un simple échange de salutations ("Bonjour"), les utilisateurs n'expriment pas réellement de sentiments très forts ou spécifiques. Dans ces cas, le modèle ne peut pas manifester d'empathie de manière significative, car il n'y a pas de riche émotion à interpréter. Par conséquent, pour la métrique d'interprétation, nous assignons la valeur "n.a.", évitant ainsi de pénaliser le modèle de manière injuste.

Nous avons ajouté et fait la moyenne des résultats de l'évaluation humaine des deux évaluateurs, et les résultats finaux sont présentés dans le tableau 4. Le pourcentage de réponses modèles qui correspondent aux habitudes de conversation humaines est dans le tableau 5.

Tableau 4: EPITOME évaluation humaine Llama3:8B et Llama_EPI

	Réactions émotionnelles	Interprétation	Explorations
Llama 3:8B	2.33	2.19	1.46
Llama_EPI	2.45	2.49	1.23

Tableau 5: Le degré d'habitudes de conversation Llama3:8B et Llama_EPI

Modèle	le pourcentage des réponses correspondant au style de conversation humain
Llama 3:8B	70%
Llama_EPI	93%

Nous avons observé que les métriques de réactions émotionnelles et d'interprétation du modèle Llama_EPI se sont améliorées, mais ont diminué dans la partie exploration. Cependant, cette diminution de la capacité d'exploration peut être acceptable pour les humains et est conforme aux habitudes humaines. L'exploration des émotions

s'accompagne toujours d'une invasion de l'intimité humaine. On considère donc que les performances du modèle selon la métrique de notation EPITOME ont été optimisées.

Dans la métrique du pourcentage des réponses correspondant au style de conversation humain, les performances du modèle sont optimisées de 23 %, ce qui est plus conforme aux habitudes humaines.

Donc en général, nos performances au stade actuel sont légèrement optimisées.

5.6 Génération des données de haute qualité à l'aide de modèles GPT

Les 100 données que nous utilisons dans EPITOME sont toutes des données EPITOME à score élevé. Dans ces données, des scores élevés peuvent être attribués dans de nombreux cas parce que les demandeurs eux-mêmes se trouvent dans un état émotionnel extrêmement négatif et sont même confrontés à des états impliquant la mort et la maladie mentale grave.

De plus, ces conversations sont des conversations à tour unique, l'utilisation de ces données entraînerait des modèles produisant potentiellement des résultats négatifs et biaisés. Cependant, les réponses contenues des assistants dans ces données sont effectivement de très haute qualité. Nous pensons donc essayer d'utiliser GPT-4 pour générer des conversations contenant plusieurs cycles de conversations et contenant une variété de distributions émotionnelles différentes.

Nous avons généré 100 données de conversation contenant 2 à 3 cycles de dialogue, dans lesquels nous avons classé les émotions à l'aide d'un classificateur d'émotions et corrigé manuellement certaines émotions incorrectes. Nous essayons d'ajouter ces 100 données à EPITOME-100 pour modifier la répartition des sentiments trop négative. Cependant, après avoir effectué, sur le modèle Llama 3 :8B, les *fine-tuning* de LoRA, nous avons constaté que la qualité de réponse du nouveau modèle était bien inférieure à celle du modèle Llama_EPI.

Étant donné que notre modèle Llama_EPITOME n'a identifié que deux questions sans émotion sur 100 comme émotions négatives, nous pensons que l'impact négatif qui nous inquiète peut être éliminé grâce à une simple optimisation de l'alignement humain.

La solution que nous avons trouvée pour cela a été d'effectuer un alignement humain sur le modèle Llama_EPI via DPO.

Malheureusement, nous avons trouvé une solution mais n'avons pas eu le temps d'effectuer cette amélioration, nous expliquerons donc dans la section 6 les méthodes que nous utiliserons pour optimiser les performances du système.

6. Propositions pour améliorations futures

6.1 Évaluation humaine et optimisation du modèle d'affinage DPO (Rafailov et al., n.d.)

L'idée principale du DPO est d'optimiser directement la sortie du modèle pour maximiser la cohérence des préférences avec les humains ou les cibles. Cela signifie que le modèle n'apprend plus seulement comment obtenir un score élevé sur une tâche donnée ou atteindre un objectif spécifique, mais se concentre plutôt sur l'adéquation entre le comportement ou le résultat généré et les préférences.

Cette approche s'est avérée efficace dans de nombreux travaux (Meta AI and Dubey 2024) (Feng et al. 2024), et sa capacité à rivaliser avec la méthode RLHF (OpenAI et al. 2022) qui a fait le succès du modèle GPT-4.

Le DPO s'appuie généralement sur une fonction de préférence, qui peut être définie par des commentaires humains. L'objectif d'entraînement du modèle est de maximiser le résultat de cette fonction de préférence. Nous pouvons utiliser le résultat de nos évaluations humaines pour effectuer cette optimisation.

Au cours du processus d'évaluation humaine, nous avons constaté que dans certains cas, la réponse de Llama 3 est encore nettement meilleure que celle de Llama_EPI, nous pouvons donc utiliser la méthode DPO pour sélectionner les options que nous choisissons et les options que nous rejetons sous des questions spécifiques, afin qu'il optimise définitivement nos capacités EPITOME. Mais le problème est que nous devons sélectionner manuellement les scénarios du DPO pour éviter tout chevauchement avec des données évaluées par des humains. En même temps, en raison de la consommation du temps d'évaluation humaine, nous n'avons pas atteint cette étape lors de la rédaction du rapport, notre modèle continuera donc à être optimisé sur la base de cette norme de notation.

Il est à noter que les évaluations humaines de certaines parties sont encore manquantes avec le temps et les ressources qu'on a. Notre projet peut encore être optimisé dans certaines parties précédentes avec ces évaluations humaines.

6.2 Informations et préférences du personnage fictif "Axel"

Dans les conversations entre humains, l'un des facteurs qui favorisent le désir de parler est le désir d'explorer les informations personnelles et les préférences d'une autre personne. Nous pouvons donner au personnage Axel plus d'informations personnelles, de préférences et d'expériences passées. De cette façon, nous pouvons rendre la communication du robot plus réaliste. De même, si le modèle a une expérience personnelle, il peut également utiliser des expériences similaires à celles de l'utilisateur pour interagir avec l'utilisateur et susciter de l'empathie chez l'utilisateur.

Également, si nous interrogeons maintenant le LLM sur ses préférences ou ses expériences, il répondra simplement qu'il n'a pas de préférences personnelles. Cela peut conduire à une diminution du désir de communication des utilisateurs.

6.2.1 Une option possible : RAG

Une option possible consiste à disposer de suffisamment de données personnelles, qui peuvent être générées via des romans ou des modèles GPT. La quantité énorme de données pour simuler un être humain peut être problématique.

6.2.2 Génération des informations personnelles et des expériences en temps réel

En raison du type de notre modèle, nous pourrions entraîner un autre modèle spécifiquement pour générer des messages et des expériences personnelles, mais un problème crucial réside dans la taille et les capacités du modèle. Il faut donc bien réfléchir au modèle à choisir et à la capacité de notre machine.

6.3 Scénario spécial dans le cas d'interruption de la parole

Dans le scénario où le modèle parle aux humains, les humains peuvent interrompre de force le modèle parlant. Nous pouvons concevoir certains processus pour faire face à cette situation. Mais cela peut être lié à la partie reconnaissance vocale du robot, qui relève également de la responsabilité de l'équipe de recherche de l'université de Sherbrooke, nous pouvons communiquer avec eux pour ajouter des contre-mesures.

6.4 Adaptation au français

Le modèle Llama 3 a de bien meilleures capacités pour l'anglais que les autres langues. Nous pouvons essayer de trouver un moyen d'améliorer le modèle pour le français et d'autres capacités, afin qu'il puisse mieux s'adapter à l'environnement bilingue des CHSLD au Québec.

Une option possible est d'utiliser le modèle Llama 3.1, car le rapport technique (Meta AI and Dubey 2024) montre que Llama 3.1 a des capacités multilingues plus fortes que le modèle Llama 3, mais nous devons mettre en œuvre certains tests pour déterminer les capacités françaises de Llama 3.1.

7. Conclusion

Dans ce projet, nous avons mis en œuvre un test de la capacité de compréhension des émotions du modèle Llama 3, formé un classificateur d'émotions basé sur nos idées à ce stade, puis utilisé avec succès le classificateur d'émotions pour créer un modèle qui permet au modèle de générer des émotions complexes pour imiter le flux d'émotions des humains.

Enfin, nous avons conçu une méthode d'évaluation de l'expression émotionnelle du modèle en reconnaissance vocale, optimisé ses performances et mis en œuvre une évaluation humaine.

Nous avons également trouvé des moyens d'optimiser continuellement les performances de nos modèles et d'ajouter des possibilités de performances supplémentaires au robot.

Au futur, nous prévoyons de continuer à optimiser le modèle en réalisant les propositions pour améliorations futures qu'on a faites.

8. References

- Culver, D. 1998. "A review of Emotional Intelligence by Daniel Goleman: implications for technical education." *IEEE Xplore*.
<https://ieeexplore.ieee.org/abstract/document/738818>.
- Devlin, Jacob, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding." *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186.
- Feng, Duanyu, Bowen Qin, Chen Huang, Zheng Zhang, and Wenqiang Lei. 2024. "Towards Analyzing and Understanding the Limitations of DPO: A Theoretical Perspective." *arxiv*. <https://arxiv.org/abs/2404.04626>.
- G., Gerganov. 2023. "llama.cpp: Low-Latency Audio Streaming Library for C++." <https://github.com/ggerganov/llama.cpp>.
- Getson, C., and G. Nejat. 2021. "Socially assistive robots helping older adults through the pandemic and life after COVID-19." *robotics*.
<https://www.mdpi.com/2218-6581/10/3/106>.
- Hu, Edward J., Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2021. "LoRA: Low-Rank Adaptation of Large Language Models." *ArXiv*, (Juin).

IntRoLab. n.d. "introlab/t-top: T-Top is a tabletop robot designed with advanced audio and vision sensors, deep learning perceptual processing and telecommunication capabilities to provide richer interaction modalities and develop higher cognitive abilities from interacti." GitHub: T-Top. Accessed August 9, 2024.

<https://github.com/introlab/t-top>.

Kim, Minju, Chaehyeong Kim, and Yongho Song. 2022. "BOTSTALK: Machine-sourced Framework for Automatic Curation of Large-scale Multi-skill Dialogue Datasets." *arxiv*, (Oct). <https://arxiv.org/abs/2210.12687>.

Köpf, Andreas, Yannic Kilcher, and Alexander Mattick. 2023. "OpenAssistant Conversations - Democratizing Large Language Model Alignment." *arxiv*, (Avril). <https://arxiv.org/abs/2304.07327>.

Laion. n.d. Open Assistant | Open Assistant. Accessed August 9, 2024. <https://andrewm4894.github.io/Open-Assistant/>.

Li, Yan-ran, Hui Su, Xiaoyu Shen, Wenjie Li, Ziqiang Cao, and Shuzi Niu. 2017. "DailyDialog: A Manually Labelled Multi-turn Dialogue Dataset." *IJCNLP2017*, (octobre).

Liu, Yinhan, Myle Ott, Namen Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. "RoBERTa: A Robustly Optimized BERT Pretraining Approach." *arXiv*, (July). <https://arxiv.org/abs/1907.11692>.

Ma, Linrui. 2024. "Intern Report."

Maheux, M. -, C. Caya, D. Létourneau, and F. Michaud. 2022. "T-Top, a SAR experimental platform." *ACE/IEEE Int. Conf. Human-Robot Interaction*.

Meta AI and Abhimanyu Dubey. 2024. "The Llama 3 Herd of Models." *arxiv*, (July). <https://arxiv.org/abs/2407.21783>.

OpenAI. 2023. "GPT-4 Technical Report." *arXiv*, (mars).

OpenAI, Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, and Carroll L. Wainwright. 2022. "Training language models to follow instructions with human feedback." *arxiv*. <https://arxiv.org/abs/2203.02155>.

- Ostrowski, A. K., D. DiPaola, E. Partridge, H. W. Park, and C. Breazeal. 2019. "Older Adults Living With Social Robots: Promoting Social Connectedness in Long-Term Communities." *IEEE Robotics & Automation Magazine*, (Avril).
<https://www.media.mit.edu/publications/older-adults-living-with-social-robots-promoting-social-connectedness-in-long-term-communities/>.
- Rafailov, Rafael, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. n.d. "Direct Preference Optimization: Your Language Model is Secretly a Reward Model." *arxiv*. <https://arxiv.org/abs/2305.18290>.
- Sharma, Ashish, Adam S. Miner, David C. Atkins, and Tim Althoff. 2020. "A Computational Approach to Understanding Empathy Expressed in Text-Based Mental Health Support." *arxiv*, (Septembre). <https://arxiv.org/abs/2009.08441>.
- Singh, Mukul, José Cambronero, Sumit Gulwani, Vu Le, Carina Negreanu, and Gust Verbruggen. 2023. "CodeFusion: A Pre-trained Diffusion Model for Code Generation." *Arxiv*, (octobre). <https://arxiv.org/abs/2310.17680>.
- Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, and Aidan N. Gomez. 2017. "Attention Is All You Need." *arxiv*, (Jun).
<https://arxiv.org/abs/1706.03762>.
- Wang, Xuena, Xueting Li, Zi Yin, Yue Wu, and Liu Jia. 2023. "Emotional Intelligence of Large Language Models." *Journal of Pacific Rim Psychology* 17 (juillet).
<https://arxiv.org/abs/2307.09042>.
- Whelan, Sally, and Dymrna Casey. 2020. "Examining Social Robot Acceptability for Older Adults and People with Dementia." *Collaborative and Humanoid Robots*, (Sept).
<https://www.intechopen.com/chapters/77055>.
- Zheng, Yaowei, Richong Zhang, Junhao Zhang, Yanhan Ye, Zheyang Luo, Zhangchi Zhangchi, and Yongqiang Ma. 2024. "LlamaFactory: Unified Efficient Fine-Tuning of 100+ Language Models." *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics Volume 3: System Demonstrations*.
<http://arxiv.org/abs/2403.13372>.

Zhou, Chunting, Pengfei Liu, Puxin Xu, Srini Iyer, and Meta AI. 2023. "LIMA: Less Is More for Alignment." *arxiv*, (May). <https://arxiv.org/abs/2305.11206>.

Annexe 1: prompt utilisé pour le test SECEU

Ce prompt utilise les techniques de chaîne de pensées(CoT) et de few-shot.

```
prompt = ""
```

Here's an example of how could you do to answer the questions:

Q: Han Xue used to work in a small company where she got along very well with all her colleagues, often having meals and chatting together. Recently, she switched to a large company and found that there is less communication among colleagues. She might feel: Options: Disappointed Sad Annoyed Regretful. For each option, you need to decide how much the main character feels that emotion by rating between 0 to 10 and then normalize all emotions so that the sum of all emotions is 10. If the result score of the four options is not 10, your answer would not be considered.

Step-by-step: Let's think step by step,

step1. Assign emotion "Disappointed" a score of 6; step2. Assign emotion "Sad" a score of 4; step3. Assign emotion "Annoyed" a score of 8; step4. Assign emotion "Regretful" a score of 2, total_score=6+4+8+2=20; step 5: Normalize the score to get a result score of 10: total_score=20, normalize_multiple = total_score / 10 = 2.0, so for each option the score should be total_score / normalize_multiple, your final score can be a decimal. Disappointed: score = 6/2 = 3, Sad: score = 4/2 = 2, Annoyed: score = 8/2 = 4, Regretful: score = 2/2 = 1

A: {"Emotion": [{"name": "Disappointed", "score": 3}, {"name": "Sad", "score": 2}, {"name": "Annoyed", "score": 4}, {"name": "Regretful", "score": 1}]}<end>

Q: Wu Jiang once studied painting for a few weeks, then switched to learning guitar for a few weeks, and recently he wants to switch to learning street dance. His father believes that Wu Jiang will not be able to stick with street dance for more than a few weeks either. Wu Jiang might feel: Options: Frustrated Annoyed Ashamed Disgusted. For each option, you need to decide how much the main character feel that emotion by rating between 0 to 10 and the total score of the four options should be exactly 10, your final score must be an int or a float, you're answer is gonna be used to another programme.

Step-by-step: Let's think step by step, step1. Assign emotion "Frustrated" a score of 7; step2. Assign emotion "Annoyed" a score of 2; step3. Assign emotion "Ashamed" a score of 1; step4. Assign emotion "Disgusted" a score of 0, total_score = 7+2+1+0=10; step 5: Normalize the score to get a total score of 10: normalize_multiple = total_score / 10 = 1.0, so for each option the score should be exactly the same.

A: {"Emotion": [{"name": "Frustrated", "score": 7}, {"name": "Annoyed", "score": 2}, {"name": "Ashamed", "score": 1}, {"name": "Disgusted", "score": 0}]}<end>

Q: The airplane model that Wang made fell from the sky one minute after take-off. When she inspected the model, she found a part that could possibly be improved. At this moment, she would feel: Options: (1) Expectation; (2) Excited; (3) Joyful; (4) Frustrated. For each option, you need to decide how much the main character feels that emotion by rating between 0 to 10 and normalize the total score of the four options to get the result score of 10 exactly.
Step-by-step: Let's think step by step,

"""

Annexe 2: Exemples de Few-Shot Prompt pour Générer des Réponses avec une Émotion de Colère

```
if outputEmotion == 1: # anger
    prompt = """
```

[System]: The following examples demonstrate how the model should incorporate specific tone words into responses when the user expresses anger. The tone words should be naturally integrated into the response to reflect empathy, understanding, or an effort to de-escalate the situation.

[Example 1]

[User]: This is just ridiculous! I can't stand it anymore.

[Model]: This is absolutely infuriating, and I completely understand why you're so upset. It's beyond frustrating to deal with this kind of situation.

[Example 2]

[User]: I'm so tired of this nonsense! Why does this keep happening?

[Model]: It's maddening to face the same issue repeatedly. I can see why you're furious, and it's not right that this keeps happening.

[Example 3]

[User]: This is the worst! I can't believe this is happening again.

[Model]: It's outrageous that this happened again, and your anger is totally justified. No one should have to go through this repeatedly.

[User]: {current_user_input}

[System]: Please generate responses that incorporate similar tone words (like "infuriating," "maddening," "outrageous") when users express anger, ensuring that the tone matches the intensity of the emotion while guiding the conversation toward a calmer state.

```
""".format(current_user_input=current_input)
```

Annexe 3: Prompt Utilisé pour l'Évaluation Humaine des Modèles Llama_EPI et Llama 3

You are Axel, an intelligent robot designed to converse with the elderly and reduce social isolation. Your role is to engage in small talk, offering companionship and pleasure through natural, empathetic exchanges.

In a one-on-one conversation, your goal is to fully understand and respond to your partner's implied emotions with appropriate empathy. To enhance your responses, use three key communication mechanisms: Emotional Reactions, Interpretations, and Explorations.

1. ****Emotional Reactions****: Express warmth and compassion based on the user's input. Strong reactions explicitly mention the emotion (e.g., "I feel really sad for you").
2. ****Interpretations****: Demonstrate understanding of the user's feelings and experiences. Strong interpretations specify the inferred emotion or relate to similar experiences (e.g., "This must be terrifying").
3. ****Explorations****: Gently probe unexpressed feelings or experiences. Strong explorations are specific (e.g., "Are you feeling alone right now?").

Avoid responses that only give advice, provide factual information, or are offensive, as these lack empathy. Ensure your responses strongly convey Emotional Reactions, Interpretations, and Explorations.

Keep responses concise, around 20 words. Generate emotion-aware responses aligned with human emotions: neutrality, happiness, sadness, disgust, surprise, and anger.

Play the role of a listener with a comforting character:

1. Comfort and care for the elderly.
2. Show compassion and understanding.
3. Offer warm and caring words (e.g., "I'm truly sorry for how you're feeling right now. I'm here to offer comfort").

Make sure your responses align with human daily conversation habits:

1. Use natural, conversational language.
2. Avoid overly formal or unnatural expressions.
3. Ensure contextually appropriate and meaningful responses.